

TLI：面向长上下文稀疏注意力的免训练轻量索引

块级上界粗筛与远/近分区预算

2026-09-30

摘要

扩展大语言模型的有效上下文长度需要突破 KV 缓存带宽的制约：在 131K 上下文的 8B 模型上，decode 每步的全量 KV 读取远超计算量，成为吞吐上限。现有方案面临一个困难权衡：training-free 的稀疏索引依赖下界近似，在长上下文检索任务上质量崩塌（我们实测 Quest 在 RULER 16K 的 multikey_3 上仅 21 分，FullKV 为 100）；训练类索引（DSA）引入可学习参数与上千步 warm-up 成本，且选择质量依赖训练分布。本文提出 TLI，一个两级 training-free 稀疏注意力索引：第一级用 4bit 量子空间上的块级 minmax **上界**粗筛保证子空间口径下无漏选，第二级用 far/near 分区的 token 级精筛保护远端关键 token 不被近端高分挤出。在 Qwen3-8B 的 LongBench 13 任务上，TLI 取得 50.54，与 FullKV (50.36) 在噪声级差距内持平；多跳 far-heavy 任务 musique 达到 34.76，为全部方法（含 FullKV）最高。RULER 上 87.93 逼近 FullKV 的 88.71，分区相对单池消融臂的增益在 16K 才转正（4K/8K 为 $-0.14/-0.25$ ，16K 为 $+0.91$ ），增益集中于多干扰检索与词表任务。速度侧，TLI 选择链相对 dense 打分取得 $1.46\times@32K \rightarrow 5.09\times@128K$ 的 kernel 级加速，64K 单请求 e2e $1.285\times$ ；全部精度代价与负结果在同机同协议下如实报告。TLI 已在 sglang 生产形态（paged 寻址、增量索引、CUDA graph）下集成。

1 引言

处理长上下文的能力正在成为大语言模型的核心竞争力。DeepSeek-R1 [1] 的长链推理、Kimi 与 Claude 的百万级上下文产品、以及长文档问答与代码仓库理解，都要求模型在一次请求中消费数万至数十万 token。然而上下文的每次延长都直接推高 KV 缓存的体量：131K 上下文配 8B 模型的 KV 读取已远超每步计算量，decode 阶段的全量 KV 访问构成带宽瓶颈，prefill 阶段同样受全注意力带宽制约。推理系统侧的进步（PagedAttention [4]、FlashAttention [3]）优化了显存组织与计算核，但没有减少需要读取的数据量本身。

减少 KV 读取量的出路在于注意力的稀疏性：softmax 归一化使少数 token 承载绝大部分 attention mass。我们在 Qwen3-8B 真实数据上的 trace 分析给出这个分布的具体形态——dense top-1024 选择的 mass 由三层构成：sink (0.37–0.71)、近端滑窗 (0.16–0.29)、远端检索 (0.02–0.29)，且远端层轮廓在同任务内跨层相关高达 0.93–1.00。这个三层结构意味着：稀疏索引要保住精度，必须同时喂饱三类性质完全不同的 attention，而它们的预算需求互相冲突。

现有方案在三类路径上各自受限。第一类，training-free 稀疏索引以 Quest [5] 为代表，用 page 内采样的最小值构造分数下界近似——下界会低估真实高分页，干扰 key 随长度超线性增多时漏选加剧，我们实测其在 RULER 16K multikey_3 上崩至 21 分 (FullKV 100)；KV 压缩方法 (SnapKV/H2O/PyramidKV [6, 7, 8]) 在 prefill 时一次性丢弃 KV，无法响应 decode 侧的查询分布。第二类，训练类索引以 DSA [13] (DeepSeek V3.2) 为代表，用可学习投影与 ReLU 打分换选择能力，需要 1000 步 warm-up 与 2.1B token 的训练预算，且选择质量依赖训练分布。第三类，两级结构 (HISA [15], COLM 2026) 验证了块级粗筛加 token 级精筛的形态有效，但其中两个正交设计维度——分数表示取上界还是下界、预算组织取分区还是全池——对质量与速度的影响尚无人系统刻画。

由此产生一个关键问题：能否设计一个 training-free、零 warm-up 的稀疏注意力索引，在不引入任何可学习参数的前提下，同时保住长上下文检索质量并兑现带宽收益？

本文提出 TLI (Training-free Lightweight Indexer) 回答这个问题。TLI 是一个两级级联的索引：第一级把 KV 缓存组织为 64-token 块，在 position-stable 低频子空间 ($d'=32$) 上维护每块的 min/max 上界并以 4bit 量化存储，query 打分取块上界的乐观侧——上界保证无漏选，任何真实高分 token 所在块必然入选；第二级把 token 预算划分为 far/near 两个池，近端滑窗强制覆盖局部性，远端池对 L1 入选块做 token 级精筛，独立配额使远端关键 token 不被近端高分挤出。两级之间以感知型 per-request gate 收尾：prefill 末段的一次 softmax 统计识别 far mass 近零的层，decode 侧安全跳过其远端检索。整个选择链 kernel 化为 fused L1 块打分、L2 级联 dual topk 与统一稀疏 attention kernel， $O(n)$ 增量索引使块界维护与序列长度无关。

本文的贡献如下：

1. **training-free 降维自由度的系统刻画**。位置稳定低频子空间在索引质量上无损失 (子空间选择对全维 top-1024 的 mass 覆盖为 0.729，全维打分自身 0.732，随机子空间 0.32)；tail32 的机理经三重判决确证为 **16 个完整最低频 RoPE 旋转对** (far 全链 mass recall 口径：频率单调——低频对 0.811 / 中频对 0.360 / 高频对 0.004；配对完整性——错位配对崩至 0.567；16 对即饱和——8 对仅 0.473)。选取方法学四象限给出可行域边界：逐维谱 (0.759) 与训练投影均败于配对纠缠；query 自适应 pair 选取 (0.865) 不可索引化；per-layer 静态 pair (0.849) 兼容索引——tail32 是零信号成本最优解。无监督 PCA 可将细筛再压至 $d=16$ 近无损 (0.766 vs 0.804)，且跨 kv-head 共享 SVD 基在 8/8 样本上追平 tail32；而训练投影在 trace 重放中成立 (92-94%)、e2e 崩坏——投影基对 decode 查询分布漂移脆弱，旋转对频率先验与查询分布无关恒稳。降维自由度来自位置先验，而非学习或自适应。
2. **far/near 分区预算**。选择索引建在 kv-head 级：同组 query head 共享同一份 kv-head 级选择，无需聚合。GQA 下远端 attention mass 在 kv-head 间极不均 (单 kv-head 可独占 0.804)，全池 top-k 使远端关键 token 被近端高分挤出。分区独立配额在双基准 e2e 上成立 (LongBench +0.25 / RULER +0.17 vs 单池)，多跳 far-heavy 任务增益最纯粹 (musique 34.76 vs 同预算单池臂 29.74, +5.02)；聚类代表方案在严格 token 预算下无一致优势，降级为消融负结果。
3. **感知型 per-request gate**。静态层掩码跨任务不泛化 (多跳任务掉 4.8-5.9 分)；prefill 末段

动态信号与 decode 侧 far 质量相关性 0.924，真实触发区间 ($\tau=0.005$) 下，开启 gate 相对关闭 gate 的差分：musique 微升 +0.23、qasper 微降 -0.41，far-heavy 任务均不崩。gate 的定位是安全省算力的保守开关，而非精度增益点。

4. **免调参的轻量配置选择**。分区参数 $\alpha/\beta/\gamma$ 的质量面在任务与层两个粒度上都高度平坦：逐任务最优选择的 oracle 上限仅 +0.08（13 任务）、逐层最优仅 +0.0008，prefill 端一次 far 统计驱动的逐样本在线选择净增益为 0。因此部署只需一组默认配置，far-heavy 多跳任务可选一次 β 上调；参数不需精调本身构成部署优势（对比 DSA 的千步 warm-up）。

2 方法

2.1 预备：标准注意力与稀疏选择问题

先回顾标准注意力。单个查询 token $q \in \mathbb{R}^{1 \times d}$ 访问 N 个 KV token ($K, V \in \mathbb{R}^{N \times d}$):

$$\text{Attn}(q, K, V) = \text{Softmax}(qK^\top) V. \quad (1)$$

稀疏索引的问题是：为 q 选出大小为 K_2 的位置集合 $I \subseteq [N]$ ，使 $\text{Attn}(q, K[I], V[I])$ 逼近全量结果。本文关注单 head 情形以保持清晰；GQA 下逐 kv-head 打分与远端 mass 的跨 head 不均性，在 § 2.2 的分区机理中讨论。与训练类索引不同，training-free 索引不允许任何参数——选择质量完全取决于用什么信号打分、以什么组织方式分配预算。

2.2 TLI 架构

TLI: training-free lightweight indexing — upper-bound block screening with far/near budget partitioning




图 1: TLI 两级索引架构：L1 块级 minmax 上界粗筛（子空间 $d'=32 + 4\text{bit}$ 量化）→ L2 far/near 分区 token 级精筛 → 统一稀疏 attention fused kernel。

与标准注意力每个查询访问全部上下文不同，TLI 为每个查询 head 选出 $K_2=1024$ 个 KV token (图 1)：

$$\text{TLI}(q, K, V) = \text{Attn}(q, K[I_{L1 \rightarrow L2}], V[I_{L1 \rightarrow L2}]), \quad (2)$$

其中 $I_{L1 \rightarrow L2}$ 由两级级联产生。TLI 的关键设计不在级联形态本身 (HISA 已验证)，而在两个正交维度上的选择：**分数表示取上界与预算组织取分区**。

L1：块级上界粗筛。把上下文按 $B=64$ 切块，块 I_i 内 token 记为 k_j 。对每块每 kv-head，在 position-stable 低频子空间 ($d'=32$) 上维护逐维 min/max ($k^{\min}, k^{\max} \in \mathbb{R}^{d'}$) 并以 4bit 量化存储 (128 维压至 40B/token-head)。查询对块的打分取上界的乐观侧：逐维按 q_d 的符号取 min/max 端值求和，构成该块对块内任意 token 点积的上界

$$s_{\text{blk}}(q, i) = \sum_{d=1}^{d'} \max(q_d k_{i,d}^{\min}, q_d k_{i,d}^{\max}) \geq \max_{j \in I_i} \langle q, k_j \rangle. \quad (3)$$

这个上界在子空间打分口径下保证无漏选：真实高分 token 所在块的子空间分数必然不低于该 token 的子空间真实分数，必然进入 top- K_1 (子空间相对全维点积是有损的，损失由 §2.3 的选取方法学单独刻画)。这与 Quest 的 page-min 下界近似形成对照——下界会低估真实高分页，漏选随干扰项增多而加剧。取 top- $K_1=128$ 块进入 L2。

L2：far/near 分区精筛。sink 与滑窗 (最近 sw_{lo} 个 token，局部性由滑窗语义天然保证，无需打分) 构成强制保留区、不占分区预算；剩余 mid 预算划分为两个池。far 池对 L1 入选块做 token 级 4bit 精筛，取 far 配额 F (128-256 饱和)；near 池对近端区做同口径精筛。分区防挤出的机理：GQA 下远端 mass 在 kv-head 间极不均 (trace 实测单 head 独占 0.804 而同组其余 head 近零)，全池 top-k 时 far 候选与近端高分 token 在同一池竞争，far-heavy 层的远端关键 token 会被系统性挤出。分区给 far 独立配额，近端扣减带 near_floor 保护防边界回退。

预算的形式定义。设查询前缀长度 $S = t + 1$ 、mid 区长度 $L_{\text{mid}} = S - |I_{\text{sink}}| - sw_{lo}$ 、近端区长度 $\ell_{\text{near}} = \lceil \alpha L_{\text{mid}} \rceil$ 。两池与最终选择集为

$$I_{\text{far}} = \text{TopK}_F \left\{ \langle q, k_j \rangle : j \in \bigcup_{i \in I_{L1}} I_i \cap [|I_{\text{sink}}|, S - sw_{lo} - \ell_{\text{near}}] \right\}, \quad (4)$$

$$I_{\text{near}} = \text{TopK}_{K_2^{\text{mid}} - F} \left\{ \langle q, k_j \rangle : j \in [S - sw_{lo} - \ell_{\text{near}}, S - sw_{lo}] \right\}, \quad (5)$$

$$I_{L1 \rightarrow L2} = I_{\text{sink}} \cup [S - sw_{lo}, t] \cup I_{\text{near}} \cup I_{\text{far}}, \quad (6)$$

其中 mid 预算 $K_2^{\text{mid}} = K_2 - |I_{\text{sink}}| - sw_{lo}$ ，far 配额 $F = \max(64, K_2^{\text{mid}} - \lfloor \gamma \lceil \ell_{\text{near}} / B \rceil B \rfloor)$ ： γ 经近端块数折算近端细筛配额，far 取剩余预算并保底 64； β 作用于 L1 的近端页预算。

维持因果性的两个设计。自回归语言模型要求查询不能访问未来 token。TLI 通过两个具体设计维持因果性：其一，**池边界即因果边界**——far 池的上界位置 $\leq t + 1 - \ell_{\text{near}} - sw_{lo}$ 、near 池 $< sw_{lo}$ ，两池的并集天然落在因果范围内，无需显式因果 mask (L1 的垃圾块也天然落池外)；其二，**早期行均匀覆盖**——首个 prefill chunk 内，行位置 t_r 小于 K_2 的早期行候选不足，若放任 topk 返回的哨兵/未来位置混入，非因果泄漏会逐层传播 (我们在 30B 模型上实测到生成重复循环崩坏，根因正是此处；8B 对同 bug 耐受未崩，如实报告)。早期行改用均匀重复 grid，等价 dense。

与 sink 和滑窗注意力的关系。sink(StreamingLLM [9])与滑窗注意力(Longformer/BigBird [10, 11])是两种成熟的静态稀疏结构, 本文将它们作为已知组件沿用: sink token 承载 0.37–0.71 的 attention mass, 滑窗承载近端局部性——两者共同构成 TLI 的强制保留区, 不占分区预算。本文的创新不在保留区本身, 而在**剩余预算在 far 检索与 near 精筛之间的分配**。作为旁证, 我们在 baseline 适配中实测: SnapKV/H2O/PyramidKV 无显式 sink 保送时在 Qwen3-8B 上首 token 即 EOS (末层 sink 权重 mean 0.592 而浅层选择信号不指向 sink, 逐层恶性畸变)——任何不显式处理 sink 的稀疏方案在该模型族上都会失真。

2.3 设计选择讨论

接下来讨论 TLI 的三个关键设计选择。

子空间选择。L1 为什么取低频尾维 32 维。索引信号必须在降维后保住对全维分数排序的区分力。Qwen3 的 rotate_half RoPE 使低频维上的点积与全维点积排序高度一致 (子空间选择对全维 top-1024 的 mass 覆盖 0.729, 全维打分自身 0.732), 随机子空间崩至 0.32、高频维 0.137。机理经三重判决确证 (图 2): Qwen3 的 128 维全部参与 RoPE, rotate_half 布局下频率 j 施加在维度对 $(j, j+64)$ 上, $\text{tail}_{32} = \text{维度 } 48..63 \text{ 与 } 112..127 = \mathbf{16 \text{ 个完整最低频旋转对}}$ 。点积按频率分解为 $\sum_j [(q_j k_j + q_{j+64} k_{j+64}) \cos(\Delta \omega_j) + (q_j k_{j+64} - q_{j+64} k_j) \sin(\Delta \omega_j)]$, 远端大 Δ 上低频项平滑高相关、高频项震荡相消——低频对承载长程检索信号。三个判决支持这个结构解释: 其一, 频率单调 (低频 16 对 0.811 / 中频 0.360 / 高频 0.004); 其二, 配对完整性 (前半取低频 16 维、后半换成中频对来源的错位配对崩至 0.567, 段位几乎重合仅元素来源错位); 其三, 对数饱和 (16 对即 0.811 近饱和, 8 对仅 0.473)。32B 上方向复现 (完整对 0.829 > 错位 0.645 > 单半 0.54), 饱和宽度后移至 24 对 (0.904)。

选取方法学的完整刻画 (表 1): 静态 (索引兼容) 与自适应 (逐 query) 两个可行域交叉出四个象限。逐维谱 top-32 仅 0.759——旋转对两元素在点积中纠缠, 逐维重要性原理上无法恢复配对结构。SparQ [12] 式逐 query $|q|$ 幅值 top-32 选取达 0.848, pair 感知自适应 (按 $|q_j| + |q_{j+64}|$ 取完整对) 达 0.865——自适应选取确有小增益, 但其子空间逐 query 变化, 与 query 到达前建好的增量 minmax 块索引结构性不兼容 (SparQ 为此付出逐 query 维度随机读取代价, 不建索引)。中间点是 per-layer 静态化: prefill 末段 q 统计的 pair 幅值 top-16 完整对, 层固定、可索引化, 0.849——保住自适应增益的七成, 比 tail32 高 3.8pt, 代价是每层一次 q 统计。**tail32 的准确定位是零信号成本可行域的最优解**, 而非全局最优; pair 静态选取是可索引化的升级路径。训练投影可以做得更准 (trace 重放 92–94%), 但 e2e 崩坏: 投影基对 decode 查询分布漂移脆弱, 而旋转对频率先验与查询分布无关恒稳。这条 trace 成立而 e2e 崩坏的口径鸿沟, 是 training-free 与训练流派之间分界线的实证刻画。

分区预算参数。预算空间由三个参数刻画: $\alpha=0.125$ (near 区比例)、 $\beta=0.375$ (near 页预算)、 $\gamma=0.125$ (near token 预算), far/near 方法取 (minmax, avg)。132 个配置点的网格加上五个方法组合臂的 e2e 给出三条规律: α 单调至边界 (越省 far 越好, 受 near_floor 制约); β 在 0.25–0.75 上平坦 (多跳任务 0.375 占优); γ 必须随 K_2 等比缩放 ($\gamma=0.5$ 在 $K_2=1024$ 下 far 仅保底 64,




图 2: 降维自由度来自位置先验: (a) tail32 = 16 个完整最低频旋转对 (频率单调、错位配对崩 0.567、16 对饱和); (b) 共享 SVD 基 $d=16$ 在 8/8 样本上追平 tail32; (c) 线性优于非线性、共享优于 per-head。

表 1: 子空间选取方法学四象限 (far 全链 mass recall, 8 样本均值)。

选取方法	信号	recall	索引兼容
逐维谱 top-32	数据驱动 (静态)	0.759	兼容
tail32	频率先验 (静态)	0.811	兼容
SparQ 式 $ q $ top-32	query 自适应	0.848	不兼容
pair 幅值 top-16 对	query 自适应	0.865	不兼容
per-layer 静态 pair	prefill q 统计	0.849	兼容

F1 崩至 13.51 的教训)。最重要的发现是平坦性本身: per-task 完美选 β 的 oracle 上限仅 +0.08, per-layer oracle 仅 +0.0008——**分区预算对配置误差不敏感, 不需要精调**。这构成部署简单性论据: 对照 DSA 的 1000 步 warm-up, TLI 一组固定配置覆盖 12/13 任务。

gate 的阈值。动态 gate 用 prefill 末段 far 统计识别 far mass 近零的层。阈值 τ 的真判决 (双任务梯度): $\tau=0.005$ 下 musique +0.23 / qasper -0.41; $\tau=0.015$ 下 +0.27 / -0.67——梯度单调, 真触发区间微损不崩 (对照静态版掉 4.8–5.9)。gate 因此定位为安全省算力的保守开关。

2.4 实现

TLI 在 sglang 生产形态下实现, 选择链由四个 kernel 组件构成:

- **fused L1 块打分**: 单个 Triton kernel 内完成 gather + 4bit 反量化 (共享 scale 表) + GEMV 打分 + 块级规约, 32K 形态 $3.6\times$;
- **L2 级联 dual kernel**: 单 launch 完成 far/near 双池打分与分区 topk, 池边界即因果边界

(替代 eager 的 fine 矩阵因果 mask);

- **统一稀疏 attention fused kernel**: gather + online softmax + bf16 直写, kernel 级 11-16 $\times$;
- **O(n) 精确增量索引**: 每 token 增量更新块界与全量重建逐位一致, 0.128ms 与序列长度无关。

系统侧三项工程对接生产: paged 寻址 (选择输出逻辑位置经 req_to_token 间接寻址 KV pool, 零拷贝); per-layer 共享 index pool 预分配 (decode 批量 select 的 launch 数与 batch size 无关); CUDA graph 捕获区零 host 同步。设计约束来自 H20 形态: Tensor Core 吞吐仅 H100 的 15% 而 HBM 带宽同级——打分类 kernel 的第一性约束是带宽而非算力, TC 化与 TMA 转置布局实测均否决 (算术强度指标显示纯 gather 路径已带宽饱和), kernel 主线是消除中间物化与合并 launch。

3 实验

3.1 端到端质量

本节在双基准上验证 TLI 的质量: RULER [16] (3 长度 $\times$ 11 任务 $\times$ n=100, NVIDIA 官方预生成) 考察长上下文检索, LongBench [17] 13 子集考察真实任务混合口径。对比方法中, TIA 是与本文同一管线下的第一代 training-free 块上界索引器 (块 min/max 上界 + 4bit 子空间量化, 无分区预算与感知 gate), 作为 TLI 最直接的结构消融对照; Quest 为下界近似的代表; KV 压缩三 baseline 走统一 monkeypatch 管线。全部实验用 Qwen3-8B [2] 真实权重; TLI 用终局配置 (sink/swa 强制保留不计入预算的严格口径)。

表 2: RULER 四方法终表(string_match_all $\times$ 100; TLI 为分区配置: (minmax, avg) 打分、 $\alpha=0.125$ 、 $\beta=0.25$ 、 $\gamma=0.125$ 、 $K_2=1024$)。

	FullKV	TIA@1024	TLI@1024	Quest@1024
4K	91.59	91.63	91.49	87.91
8K	89.14	88.90	88.62	81.76
16K	85.41	84.53	83.68	70.18
总 AVG	88.71	88.35	87.93	79.95

如表所示, 三个观察成立。其一, TLI 对 Quest 的领先随长度超线性扩大 (+3.58 $\rightarrow$ +6.86 $\rightarrow$ +13.50): 16K 档 Quest 在多干扰检索任务上崩塌, TLI 同任务保持量级正确——根因是下界近似漏选随干扰项增多加剧, 上界粗筛无此劣化。其二, 分区相对单池消融臂的增益在 16K 才转正 (4K/8K 为 -0.14/-0.25, 16K 为 +0.91): 超长上下文是分区 far 检索的收益区, 16K 的分区增益集中于 multikey_3 (+5.0) 与 cwe (+5.4), 均为 vs 同配置单池臂的差分。其三, 绝对值解读须以同长度 FullKV 为基线——聚合列举类任务 FullKV 自身随长度退化 (multivalue 89.5 $\rightarrow$ 69.25 $\rightarrow$ 44.25 是模型列举能力上限), 稀疏方法在同长度上的差距才是稀疏效应。

LongBench 13 子集上 (表 3), TLI **50.54**——与 FullKV 50.36 持平 (+0.18, 噪声级边缘, Limitations 一节如实标注), vs Quest +2.82。增益的结构清晰: 多跳 far-heavy 任务 musique 34.76 为全部方法最高 (vs FullKV +2.62、vs 同预算单池臂 +5.02), 是分区 far 检索的直接证据; 其余 12 任务在 0 ~ -0.44 噪声级互有胜负。KV 压缩三 baseline 的全量崩坏坐实 sink 论断: SnapKV 27.70 / H2O 更崩 (musique 0.63、hotpotqa 2.68) ——无显式 sink 保送时 Qwen3-8B 首 token 即 EOS (§2.2 末段机理), 三者中仅代码类任务 (lcc 67.19 / 54.06) 部分幸存。预算配比的任务形态依赖性如实并报: LongBench 多跳任务 $\beta=0.375$ 占优 (50.54 行), RULER 合成 needle $\beta=0.25$ 占优 (87.93 行) ——两行并报, 使用者按任务形态选择。逐任务族分解给出 β 让渡的边界判据: 真实任务全族成立 (最 far-heavy 的 musique 反而增益最大 +1.94), 合成 far-dense 族失效 (multikey_3 -2.00: far 候选数量爆炸使预算粒度主导) ——far-dense 检索是稀疏索引器全族难区 (Quest 同任务同构崩塌), 非 β 配比独有问题。

表 3: LongBench 13 子集终表 (各任务官方口径平均; KV 压缩三 baseline = 统一 monkeypatch 管线 + 1024 预算, 无 sink 保送适配)。

	FullKV	Quest	TIA	TLI	SnapKV	H2O	PyramidKV
总分	50.36	47.72	50.06	50.54	27.70	14.87	28.82
musique	32.14	27.09	32.28	34.76	8.61	0.63	8.99

3.2 消融

子空间 (A)。低频 $d'=32$ 对全维 top-1024 的 mass 覆盖 0.729, 全维打分自身 0.732 (随机 0.32、高频 0.137 崩溃) ——位置稳定子空间存在。机理三重判决: tail32 = 16 个完整最低频旋转对 (频率单调 0.811/0.360/0.004、错位配对崩 0.567、16 对饱和); 选取方法学四象限 (表 1) 刻画可行域——逐维谱 0.759 与训练投影均败于配对纠缠, query 自适应 pair 选取 0.865 是 oracle 上界但不可索引化, per-layer 静态 pair 0.849 兼容索引, tail32 是零信号成本最优。降维三段判决: 无监督 PCA $d=16$ 近无损 (0.766 vs 0.804) 是唯一推荐; 训练投影 trace 成立 e2e 崩 (口径鸿沟); 非线性 (UMAP/t-SNE) 质量无增益且 fit 成本 80–167s/层-样本 vs 增量索引 0.128ms/token, 四个数量级不可行。跨 kv-head 共享 SVD 基 $d=16$ 在 8/8 样本追平 tail32 且优于 per-head 基——GQA head 冗余使 MLA 式单投影缓存的 training-free 代理可行。

分区。far 区 token 级精筛接近 oracle (far-heavy 层 0.999); 聚类代表在严格 token 预算下无一致优势 (块 scatter-amax 0.09–0.39 最差) 且聚类中心非上界有漏选理论空洞——降级为负结果。分区 vs 单池 e2e 双基准成立 (LongBench +0.25 / RULER +0.17), 与 trace 重放口径 (宽预算下单池微胜) 的分歧坐实: **分区收益的本质是紧预算下的预算分配, 而非候选质量。**

层跳过 (D')。离线平均轮廓可跳 13/36 层 (precision 0.92–1.00) 但全局静态掩码跨任务不泛化 (多跳掉 4.8–5.9); prefill 动态信号 corr 0.924 防住反向错误, 真触发区间微损不崩——gate 是安全开关。

自适应 α/β 的否定。 per-request 在线分派 α/β 判 No-Go: oracle 上限 LongBench +0.08 / RULER +0.00, 且 +0.08 全部可由噪声正向选择偏差解释 (非 musique 12 任务 $|\Delta|$ 中位 0.17)。信号零成本可得, 但参数面平坦使自适应无杠杆。同一信号的最佳用途是 gate (安全价值) 而非 β 分派 (无精度价值)。粒度细化到层同样无杠杆 (per-layer oracle 增益均值 +0.0008) ——任务与层两粒度双重否定, 转译为部署简单性论据。

离线重放与端到端的口径鸿沟。 我们对五种近/远端打分组合做了离线 trace 重放与端到端评测的双重排名: 重放质量排名第 4 的组合 (近端取均值聚合的配置) 在端到端评测中取得全场最高分 50.54——两种口径的排名系统性反转。这说明离线代理指标不能替代端到端评测, kernel microbench 与 e2e 必须都测都报告。

3.3 Kernel 级 Microbench

选择链相对 dense 全维打分的加速比: 32K 1.46 $\times$ 、64K 2.77 $\times$ 、128K 5.09 $\times$ (合成数据已标注, trace 重放口径)。同机三方对比 (官方 kernel 原样接入统一 harness, 131K cudaEvent): Quest 0.107ms / DSA 0.503ms / TLI 0.787ms。延迟排名 Quest < DSA < TLI, 如实报告——TLI 当前的优势在算法结构侧: 每 token 索引 MAC ≈ 258 (DSA 的 1/32)、索引存储 3 $\times$ 低于 Quest、质量 vs Quest LongBench +2.82 / RULER +7.98。131K 下三家都远离 HBM bound, 排名反映实现成熟度而非算法上界。

3.4 端到端速度

e2e 终值 (Qwen3-30B-A3B, H2O $\times 2$): 64K 单请求 1.285 $\times$ (16.39s vs dense 21.06s) ——稀疏理论流量收益首次在 e2e 净兑现; 32K 档 0.77 $\times$ (短上下文固定开销未能覆盖); TP2 bs16 64K 档 0.92 $\times$, 差 8% 如实归因为 launch-bound (逐请求 Python 循环使 GPU 名义满载而带宽 util 仅 10–11%), 跨请求批量化已验证 3.8 $\times$ 为修复方向。8B 稳态 (bs16 $\times$ S=30K $\times$ n=256): prefill 733.9 $\rightarrow$ 183.4s (4.00 $\times$), decode step 65.0 $\rightarrow$ 33.5ms (1.94 $\times$, 反超 dense 的 40.4ms)。

3.5 Profiling 方法论发现

逐 kernel microbench 与生产 e2e 存在系统性口径差: select 热路径的 3 处 host 同步 (.item() 与 .any()) 在生产形态造成约 10 万次队列排空, 合成 bench 无 GPU 队列时完全测不出, 消除后同型负载 prefill 降低 6.7%。同步消除类优化必须在 e2e 层验证。我们将此与离线重放排名不可替代 e2e 判决的观察合并为一条方法论: kernel 级与 e2e 两层评测都测、都诚实报告。

4 相关工作

稀疏注意力索引。 Quest 用 page 采样构造下界近似, KV 压缩类 (SnapKV/H2O/PyramidKV) 在 prefill 时一次性丢弃 KV。TLI 与它们的差异在三点: 分数表示取上界 (vs 下界——上界家族在 RULER 总 AVG 上领先 Quest +8.40, 是长上下文质量分化的主要根源)、预算组织取分区 (vs

全池)、两级级联 (vs 单级)。我们在统一口径适配 SnapKV/H2O/PyramidKV 时发现：无显式 sink 保送的实现在 Qwen3-8B 上首 token 即 EOS——sink 在浅层不获选择信号但承载深层 0.59 的 attention mass，逐层恶性畸变。这既是对这类 baseline 适配的公平性修正，也旁证 sink 保送的必要性。

训练类索引。 DSA [13] (DeepSeek V3.2) 用 $I = \sum w \cdot \text{ReLU}(q \cdot k)$ 训练选择器，64 头 $\times$ 128 维 FP8 top-2048，warm-up 1000 步；MoBA [14] 用门控块稀疏。TLI training-free/weight-free，与其在 kernel 级统一 harness 对比。两者构成方法论分界：DSA 用训练换选择能力，可学任意投影；training-free 只能依赖与查询分布无关的位置先验——trace 离线成立而 e2e 崩坏的口径鸿沟正是这条分界线的实证刻画。

两级结构。 HISA (COLM 2026) 验证 block-coarse + token-refine 形态有效——「two-level」本身不是本文创新。TLI 的增量是两个正交维度的系统刻画：表示 (上界 vs 下界) 与预算组织 (分区 vs 全池) 的质量-速度影响。

推理系统。 FlashAttention 系优化计算核，PagedAttention/vLLM 优化显存组织。TLI 与它们正交，在 sglang 生产形态集成。

5 局限与未来工作

精度侧：LongBench 首超 FullKV 的幅度在噪声边缘 (+0.18)；RULER 最优臂 87.93 仍低于 FullKV 88.71 (-0.78)，残余代价集中于 multikey_3 (16K: 75-80 vs TIA 89)——4bit 预算粒度在超多干扰 key 任务上主导。速度侧：多请求批量形态仍差 dense 8% (launch-bound)，跨请求批量化 forward_extend 为明确修复方向；三方 indexer 延迟排名当前第三，跨请求批量化的 kernel 化为兑现路径。规模侧：子空间机制在 Qwen3-32B 上强度递减 (entry recall 口径 0.66-0.87 vs 全维差距 ≤ 0.08 ，机制存在、如实报告)；MLA 架构的 latent 索引 (DeepSeek 系) 是 future work。gate 的 far 统计为 per-layer 单值，混合 batch 下跨请求污染 (生产语义应 per-row)。

附录 A：实验编号总索引

全部实验编号与系统里程碑的脚本到结论映射 (含 commit 号、对拍口径、负结果入册) 见随源码发布的配套实验日志。

附录 B：可复现性

H20-3e $\times$ 2 (141GB)，torch 2.8.0+cu128，sglang two-level-indexer 分支；RULER 官方预生成 (KVCache-Factory 镜像) / LongBench v1 全量 / Qwen3-8B、30B-A3B、32B 真实权重；string_match_all 官方口径打分；e2e 差分法采用稀疏/稠密配置交替运行的对照方式。

参考文献

- [1] DeepSeek-AI. DeepSeek-R1: Incentivizing Reasoning Capability in LLMs via Reinforcement Learning. arXiv:2501.14348, 2025.
- [2] Qwen Team. Qwen3 Technical Report. arXiv:2505.09388, 2025.
- [3] T. Dao, D. Y. Fu, S. Ermon, A. Rudra, and C. Ré. FlashAttention: Fast and Memory-Efficient Exact Attention with IO-Awareness. In *NeurIPS*, 2022.
- [4] W. Kwon, Z. Li, S. Zhuang, Y. Sheng, L. Zheng, C. H. Yu, J. E. Gonzalez, H. Zhang, and I. Stoica. Efficient Memory Management for Large Language Model Serving with PagedAttention. In *SOSP*, 2023.
- [5] Y. Tang, L. Lin, Y. Cao, S. Li, F. Yang, Y. Wang, and T. Wu. Quest: Query-Aware Sparsity for Efficient Long-Context LLM Inference. In *ICLR*, 2025.
- [6] Y. Li, Y. Huang, B. Yang, Y. Li, Y. Liu, and M. Qiu. SnapKV: LLM Knows What You Are Looking For Before Generation. In *NeurIPS*, 2024.
- [7] Z. Zhang, Y. Sheng, T. Zhou, D. Chen, L. Zheng, B. Chen, L. Cai, M. Yan, Y. Yu, J. Tang, J. Xu, P. Zhang, and R. Chen. H2O: Heavy-Hitter Oracle for Efficient Generative Inference of Large Language Models. In *NeurIPS*, 2023.
- [8] Z. Cai, Y. Zhang, B. Wang, X. Liu, H. Zhao, Y. Lu, Y. Wang, X. Sun, K. Liu, and Z. Duan. PyramidKV: Dynamic KV Cache Compression Based on Pyramidal Information Funneling. arXiv:2406.02069, 2024.
- [9] G. Xiao, Y. Tian, B. Chen, S. Han, and M. Lewis. Efficient Streaming Language Models with Attention Sinks. In *ICLR*, 2024.
- [10] I. Beltagy, M. E. Peters, and A. Cohan. Longformer: The Long-Document Transformer. arXiv:1904.07785, 2020.
- [11] M. Zaheer, M. Guruganesh, K. A. Dubey, J. Ainslie, C. Alberti, S. Ontañón, P. Pham, A. Ravula, Q. Wang, L. Yang, and A. Ahmed. Big Bird: Transformers for Longer Sequences. In *NeurIPS*, 2020.
- [12] SparQ Attention: Accelerating LLM Inference with Accurate KV Retrieval, Minimized Decoding Costs, and No Fine-Tuning. arXiv:2406.09050, 2024.
- [13] DeepSeek-AI. DeepSeek-V3.2-Exp Technical Report: Boosting Long-Context Efficiency with Exact Sparse Attention. 2025.
- [14] Moonshot AI. MoBA: Mixture of Block Attention for Efficient Long-Context LLMs. arXiv:2502.13189, 2025.
- [15] HISA: Efficient Hierarchical Indexing for Fine-Grained Sparse Attention. In *COLM*, 2026. arXiv:2603.28458.

- [16] C.-P. Hsieh, S. Sun, S. Krizan, S. Ganti, J. Zhang, B. Kulis, K. Papayiannis, M. Fofanos, N. Rudra-jit, and C. Tigges. RULER: What’s the Real Context Size of Your Long-Context Language Models? arXiv:2404.06654, 2024.
- [17] Y. Bai, X. Lv, J. Zhang, H. Zhao, X. Qi, L. Huang, Z. Du, X. Wang, Y. Zheng, Y. Zheng, J. Zhang, Y. Li, T. Su, and J. Tang. LongBench: A Bilingual, Multitask Benchmark for Long Context Understanding. In *ACL*, 2024.