

TLI：面向长上下文稀疏注意力的免训练轻量索引

块级上界粗筛与远/近分区预算

2026-09-30

摘要

扩展大语言模型的有效上下文长度需要突破 KV 缓存带宽的制约：在 131K 上下文的 8B 模型上，decode 每步的全量 KV 读取远超计算量，成为吞吐上限。现有方案面临一个困难权衡：training-free 的稀疏索引依赖下界近似，在长上下文检索任务上质量崩塌（我们实测 Quest 在 RULER 16K 的 multikey_3 上仅 21 分，FullKV 为 100）；训练类索引（DSA）引入可学习参数与上千步 warm-up 成本，且选择质量依赖训练分布。本文提出 TLI，一个两级 training-free 稀疏注意力索引：第一级用 4bit 量子空间上的块级 minmax 上界粗筛保证子空间口径下无漏选，第二级用 far/near 分区的 token 级精筛保护远端关键 token 不被近端高分挤出。在 Qwen3-8B 的 LongBench 13 任务上，TLI 取得 50.54，与 FullKV (50.36) 在噪声级差距内持平；多跳 far-heavy 任务 musique 达到 34.76，为全部方法（含 FullKV）最高。RULER 上 87.93 逼近 FullKV 的 88.71，分区相对单池消融臂的增益在 16K 才转正（4K/8K 为 $-0.14/-0.25$ ，16K 为 $+0.91$ ），增益集中于多干扰检索与词表任务。速度侧，选择链相对 dense 打分取得 $1.46\times@32K \rightarrow 5.09\times@128K$ 的 kernel 级加速；同机三方对比中 Quest 单 kernel 延迟更低（0.107ms vs TLI 0.787ms），TLI 的速度优势在索引计算量（DSA 的 $1/32$ ）与索引存储总量（336B/token vs Quest 约 1KB/token，全 head 汇总口径）而非延迟；e2e 收益有形状边界：64K 单请求 $1.285\times$ ，32K 档 $0.77\times$ 、高并发档 $0.92\times$ （固定开销与 launch-bound 所致）。全部精度代价与负结果在同机同协议下如实报告。TLI 已在 sglang 生产形态（paged 寻址、增量索引、CUDA graph）下集成。

1 引言

处理长上下文的能力正在成为大语言模型的核心竞争力。DeepSeek-R1 [1] 的长链推理、Kimi 与 Claude 的百万级上下文产品、以及长文档问答与代码仓库理解，都要求模型在一次请求中消费数万至数十万 token。然而上下文的每次延长都直接推高 KV 缓存的体量：131K 上下文配 8B 模型的 KV 读取已远超每步计算量，decode 阶段的全量 KV 访问构成带宽瓶颈，prefill 阶段同样受全注意力带宽制约。推理系统侧的进步（PagedAttention [4]、FlashAttention [3]）优化了显存组织与计算核，但没有减少需要读取的数据量本身。

减少 KV 读取量的出路在于注意力的稀疏性：softmax 归一化使少数 token 承载绝大部分 attention mass。我们在 Qwen3-8B 真实数据上的 trace 分析给出这个分布的具体形态——dense top-1024 选择的 mass 由三层构成：sink (0.37–0.71)、近端滑窗 (0.16–0.29)、远端检索 (0.02–0.29)，

且远端层轮廓在同任务内跨层相关高达 0.93–1.00。这个三层结构意味着：稀疏索引要保住精度，必须同时喂饱三类性质完全不同的 attention，而它们的预算需求互相冲突。

现有方案在三类路径上各自受限。第一类，training-free 稀疏索引以 Quest [5] 为代表，用 page 内采样的最小值构造分数下界近似——下界会低估真实高分页，干扰 key 随长度超线性增多时漏选加剧，我们实测其在 RULER 16K multikey_3 上崩至 21 分 (FullKV 100)；KV 压缩方法 (SnapKV/H2O/PyramidKV [6, 7, 8]) 在 prefill 时一次性丢弃 KV，无法响应 decode 侧的查询分布。第二类，训练类索引以 DSA [13] (DeepSeek V3.2) 为代表，用可学习投影与 ReLU 打分换选择能力，需要 1000 步 warm-up 与 2.1B token 的训练预算，且选择质量依赖训练分布。第三类，两级结构 (HISA [15], COLM 2026) 验证了块级粗筛加 token 级精筛的形态有效，但其中两个正交设计维度——分数表示取上界还是下界、预算组织取分区还是全池——对质量与速度的影响尚无人系统刻画。

由此产生一个关键问题：能否设计一个 training-free、零 warm-up 的稀疏注意力索引，在不引入任何可学习参数的前提下，同时保住长上下文检索质量并兑现带宽收益？

本文提出 TLI (Training-free Lightweight Indexer) 回答这个问题。TLI 是一个两级级联的索引：第一级把 KV 缓存组织为 64-token 块，在 position-stable 低频子空间 ($d'=32$) 上维护每块的 min/max 上界并以 4bit 量化存储，query 打分取块上界的乐观侧——上界保证无漏选，任何真实高分 token 所在块必然入选；第二级把 token 预算划分为 far/near 两个池，近端滑窗强制覆盖局部性，远端池对 L1 入选块做 token 级精筛，独立配额使远端关键 token 不被近端高分挤出。两级之间以感知型 per-request gate 收尾：prefill 末段的一次 softmax 统计识别 far mass 近零的层，decode 侧安全跳过其远端检索。整个选择链 kernel 化为 fused L1 块打分、L2 级联 dual topk 与统一稀疏 attention kernel， $O(n)$ 增量索引使块界维护与序列长度无关。

本文的贡献如下：

1. **training-free 降维自由度的系统刻画。**位置稳定低频子空间在索引质量上无损失（子空间选择对全维 top-1024 的 mass 覆盖为 0.729，同管线 $d'=128$ 臂（含 4bit 量化与级联损失）为 0.732，随机子空间 0.32）；tail32 的机理经三重判决确证为 **16 个完整最低频 RoPE 旋转对**（far 区召回 R_{far} 口径：频率单调——低频对 0.811 / 中频对 0.360 / 高频对 0.004；配对完整性——错位配对崩至 0.567；16 对即饱和——8 对仅 0.473）。选取方法学四象限给出可行域边界：逐维谱 (0.759) 与训练投影均败于配对纠缠；query 自适应 pair 选取 (0.865) 不可索引化；per-layer 静态 pair (0.849) 兼容索引但 e2e 反转（重放 +3.8pt、e2e -0.50）——tail32 是经 e2e 验证的零信号成本最优解。无监督 PCA 可将细筛再压至 $d=16$ 近无损 (0.766 vs 0.804)，且跨 kv-head 共享 SVD 基在 8/8 样本上追平 tail32；而训练投影在 trace 重放中成立 (92–94%)、e2e 崩坏——投影基对 decode 查询分布漂移脆弱，旋转对频率先验与查询分布无关恒稳。降维自由度来自位置先验，而非学习或自适应。
2. **far/near 分区预算。**选择索引建在 kv-head 级：同组 query head 共享同一份 kv-head 级选择，无需聚合。GQA 下远端 attention mass 在 kv-head 间极不均（单 kv-head 可独占 0.804 的 far 注意质量），全池 top-k 使远端关键 token 被近端高分挤出。分区独立配额在双基准 e2e

上成立 (LongBench +0.38 = 50.54–50.16、RULER +0.17 = 87.93–87.76 vs 单池, 均为主表口径可直接验算), 多跳 far-heavy 任务增益最纯粹 (musique 34.76 vs 同预算单池臂 29.74, +5.02); 聚类代表方案在严格 token 预算下无一致优势, 降级为消融负结果。

3. **感知型 per-request gate**。静态层掩码跨任务不泛化 (多跳任务掉 4.8–5.9 分); prefill 末段动态信号与 decode 侧 far 质量相关性 0.924, 真实触发区间 ($\tau=0.005$) 下, 开启 gate 相对关闭 gate 的差分: musique 微升 +0.23、qasper 微降 -0.41, far-heavy 任务均不崩。gate 的定位是安全省算力的保守开关, 而非精度增益点。
4. **免调参的轻量配置选择**。分区参数 $\alpha/\beta/\gamma$ 的质量面在任务与层两个粒度上都高度平坦: 逐任务最优选择的 oracle 上限仅 +0.08 (13 任务)、逐层最优仅 +0.0008, prefill 端一次 far 统计驱动的逐样本在线选择净增益为 0。因此部署只需一组默认配置, far-heavy 多跳任务可选一次 β 上调; 参数不需精调本身构成部署优势 (对比 DSA 的千步 warm-up)。

2 方法

2.1 预备: 标准注意力与稀疏选择问题

先回顾标准注意力。单个查询 token $q \in \mathbb{R}^{1 \times d}$ 访问 N 个 KV token ($K, V \in \mathbb{R}^{N \times d}$):

$$\text{Attn}(q, K, V) = \text{Softmax}(qK^\top) V. \quad (1)$$

稀疏索引的问题是: 为 q 选出大小为 K_2 的位置集合 $I \subseteq [N]$, 使 $\text{Attn}(q, K[I], V[I])$ 逼近全量结果。本文关注单 head 情形以保持清晰; GQA 下逐 kv-head 打分与远端 mass 的跨 head 不均性, 在 § 2.2 的分区机理中讨论。与训练类索引不同, training-free 索引不允许任何参数——选择质量完全取决于用什么信号打分、以什么组织方式分配预算。

2.2 TLI 架构

与标准注意力每个查询访问全部上下文不同, TLI 为每个查询 head 选出 $K_2=1024$ 个 KV token (图 1):

$$\text{TLI}(q, K, V) = \text{Attn}(q, K[I_{L1 \rightarrow L2}], V[I_{L1 \rightarrow L2}]), \quad (2)$$

其中 $I_{L1 \rightarrow L2}$ 由两级级联产生。TLI 的关键设计不在级联形态本身 (HISA 已验证), 而在两个正交维度上的选择: **分数表示取上界与预算组织取分区**。

L1: 块级上界粗筛。把上下文按 $B=64$ 切块, 块 I_i 内 token 记为 k_j 。对每块每 kv-head, 在 position-stable 低频子空间 ($d'=32$) 上维护逐维 min/max ($k_i^{\min}, k_i^{\max} \in \mathbb{R}^{d'}$) 并以 4bit 量化存储 (128 维压至 40B/token-head)。查询对块的打分取上界的乐观侧: 逐维按 q_d 的符号取 min/max 端值求和, 构成该块对块内任意 token 点积的上界

$$s_{\text{blk}}(q, i) = \sum_{d=1}^{d'} \max(q_d k_{i,d}^{\min}, q_d k_{i,d}^{\max}) \geq \max_{j \in I_i} \langle q, k_j \rangle. \quad (3)$$

TLI: training-free lightweight indexing — upper-bound block screening with far/near budget partitioning




图 1: TLI 两级索引架构: L1 块级 minmax 上界粗筛 (子空间 $d'=32 + 4\text{bit}$ 量化) $\rightarrow$ L2 far/near 分区 token 级精筛 $\rightarrow$ 统一稀疏 attention fused kernel。

这个上界在子空间打分口径下保证无漏选: 真实高分 token 所在块的子空间分数必然不低于该 token 的子空间真实分数, 必然进入 top- K_1 (子空间相对全维点积是有损的, 损失由 §2.3 的选取方法学单独刻画)。这与 Quest 的 page-min 下界近似形成对照——下界会低估真实高分页, 漏选随干扰项增多而加剧。取 top- $K_1=128$ 块进入 L2。

L2: far/near 分区精筛。 sink 与滑窗 (最近 sw_{lo} 个 token, 局部性由滑窗语义天然保证, 无需打分) 构成强制保留区、不占分区预算; 剩余 mid 预算划分为两个池。far 池对 L1 入选块做 token 级 4bit 精筛, 取 far 配额 F (128–256 饱和); near 池对近端区做同口径精筛。分区防挤出的机理: GQA 下远端 mass 在 kv-head 间极不均 (trace 实测单 head 独占 0.804 而同组其余 head 近零), 全池 top-k 时 far 候选与近端高分 token 在同一池竞争, far-heavy 层的远端关键 token 会被系统性挤出。分区给 far 独立配额, 近端扣减带 near_floor 保护防边界回退。

预算的形式定义。 设查询前缀长度 $S = t + 1$ 、mid 区长度 $L_{mid} = S - |I_{sink}| - sw_{lo}$ 、近端区长度 $\ell_{near} = \lceil \alpha L_{mid} \rceil$ 。两池与最终选择集为

$$I_{far} = \text{TopK}_F \left\{ \langle q, k_j \rangle : j \in \bigcup_{i \in I_{L1}} I_i \cap [|I_{sink}|, S - sw_{lo} - \ell_{near}] \right\}, \quad (4)$$

$$I_{near} = \text{TopK}_{K_2^{\text{mid}} - F} \left\{ \langle q, k_j \rangle : j \in [S - sw_{lo} - \ell_{near}, S - sw_{lo}] \right\}, \quad (5)$$

$$I_{L1 \rightarrow L2} = I_{sink} \cup [S - sw_{lo}, t] \cup I_{near} \cup I_{far}, \quad (6)$$

其中 mid 预算 $K_2^{\text{mid}} = K_2 - |I_{sink}| - sw_{lo}$, far 配额 $F = \max(64, K_2^{\text{mid}} - \lceil \gamma \lceil \ell_{near} / B \rceil B \rceil)$: γ 经近端块数折算近端细筛配额, far 取剩余预算并保底 64; β 作用于 L1 的近端页预算。

维持因果性的两个设计。 自回归语言模型要求查询不能访问未来 token。TLI 通过两个具体设计维持因果性: 其一, **池边界即因果边界**——far 池的上界位置 $\leq t + 1 - \ell_{near} - sw_{lo}$ 、near 池 $< sw_{lo}$, 两池的并集天然落在因果范围内, 无需显式因果 mask (L1 的垃圾块也天然落池外); 其

二，**早期行均匀覆盖**——首个 prefill chunk 内，行位置 t_r 小于 K_2 的早期行候选不足，若放任 topk 返回的哨兵/未来位置混入，非因果泄漏会逐层传播（我们在 30B 模型上实测到生成重复循环崩坏，根因正是此处；8B 对同 bug 耐受未崩，如实报告）。早期行改用均匀重复 grid，等价 dense。

与 sink 和滑窗注意力的关系。sink(StreamingLLM [9])与滑窗注意力(Longformer/BigBird [10, 11])是两种成熟的静态稀疏结构，本文将它们作为已知组件沿用：sink token 承载 0.37–0.71 的 attention mass，滑窗承载近端局部性——两者共同构成 TLI 的强制保留区，不占分区预算。本文的创新不在保留区本身，而在**剩余预算在 far 检索与 near 精筛之间的分配**。作为旁证，我们在 baseline 适配中实测：SnapKV/H2O/PyramidKV 无显式 sink 保送时在 Qwen3-8B 上首 token 即 EOS（末层 sink 权重 mean 0.592 而浅层选择信号不指向 sink，逐层恶性畸变）——任何不显式处理 sink 的稀疏方案在该模型族上都会失真。

2.3 设计选择讨论

接下来讨论 TLI 的三个关键设计选择。

子空间选择。L1 为什么取低频尾维 32 维。索引信号必须在降维后保住对全维分数排序的区分力。Qwen3 的 rotate_half RoPE 使低频维上的点积与全维点积排序高度一致（子空间选择对全维 top-1024 的选择覆盖 $C=0.729$ ，同管线 $d'=128$ 臂（含 4bit 量化与级联损失）为 0.732），随机子空间崩至 0.32、高频维 0.137。机理经三重判决确证（图 2）：Qwen3 的 128 维全部参与 RoPE，rotate_half 布局下频率 j 施加在维度对 $(j, j+64)$ 上，tail32 = 维度 48..63 与 112..127 = **16 个完整最低频旋转对**。点积按频率分解为 $\sum_j [(q_j k_j + q_{j+64} k_{j+64}) \cos(\Delta \omega_j) + (q_j k_{j+64} - q_{j+64} k_j) \sin(\Delta \omega_j)]$ ，远端大 Δ 上低频项平滑高相关、高频项震荡相消——低频对承载长程检索信号。三个判决支持这个结构解释：其一，频率单调（far 区召回 R_{far} ：低频 16 对 0.811 / 中频 0.360 / 高频 0.004）；其二，配对完整性（前半取低频 16 维、后半换成中频对来源的错位配对崩至 0.567，段位几乎重合仅元素来源错位）；其三，对数饱和（16 对即 0.811 近饱和，8 对仅 0.473）。32B 上方向复现（完整对 0.829 > 错位 0.645 > 单半 0.54），饱和宽度后移至 24 对（0.904）。

选取方法学的完整刻画（表 1）：静态（索引兼容）与自适应（逐 query）两个可行域交叉出四个象限。逐维谱 top-32 仅 0.759——旋转对两元素在点积中纠缠，逐维重要性原理上无法恢复配对结构。SparQ [12] 式逐 query $|q|$ 幅值 top-32 选取达 0.848，pair 感知自适应（按 $|q_j| + |q_{j+64}|$ 取完整对）达 0.865——自适应选取确有小增益，但其子空间逐 query 变化，与 query 到达前建好的增量 minmax 块索引结构性不兼容（SparQ 为此付出逐 query 维度随机读取代价，不建索引）。中间点是 per-layer 静态化：prefill 末段 q 统计的 pair 幅值 top-16 完整对，层固定、可索引化，0.849——保住自适应增益的七成，比 tail32 高 3.8pt，代价是每层一次 q 统计。**tail32 的准确定位是零信号成本可行域的最优解**，而非全局最优；pair 静态选取在结构上可索引化，但其 e2e 验证我们已做：static pair 臂（同配置换 prefill q 统计选 pair）在重放口径 +3.8pt，e2e 却为 -0.50 (50.04 vs 50.54, musique -5.27)——prefill 统计派生的选择基与训练投影同构，在 decode 查询分布漂移下同样失效，重放增益不可外推。训练投影可以做得更准 (trace 重放 92–94%)，但 e2e 崩坏：投影基对 decode 查询分布漂移脆弱，而旋转对频率先验与查询分布无关恒稳。这条 trace 成立而 e2e 崩

坏的口径鸿沟，是 training-free 与训练流派之间分界线的实证刻画。




图 2: 降维自由度来自位置先验: (a) tail32 = 16 个完整最低频旋转对 (频率单调、错位配对崩 0.567、16 对饱和); (b) 共享 SVD 基 $d=16$ 在 8/8 样本上追平 tail32; (c) 线性优于非线性、共享优于 per-head。

表 1: 子空间选取方法学四象限 (far 区召回 R_{far} , 8 样本均值)。

选取方法	信号	recall	索引兼容
逐维谱 top-32	数据驱动 (静态)	0.759	兼容
tail32	频率先验 (静态)	0.811	兼容
SparQ 式 $ q $ top-32	query 自适应	0.848	不兼容
pair 幅值 top-16 对	query 自适应	0.865	不兼容
per-layer 静态 pair	prefill q 统计	0.849	兼容

分区预算参数。预算空间由三个参数刻画: $\alpha=0.125$ (near 区比例)、 $\beta=0.375$ (near 页预算)、 $\gamma=0.125$ (near token 预算), far/near 方法取 (minmax, avg)。132 个配置点的网格加上五个方法组合臂的 e2e 给出三条规律: α 单调至边界 (越省 far 越好, 受 near_floor 制约); β 在 0.25–0.75 上平坦 (多跳任务 0.375 占优); γ 必须随 K_2 等比缩放 ($\gamma=0.5$ 在 $K_2=1024$ 下 far 仅保底 64, F1 崩至 13.51 的教训)。最重要的发现是平坦性本身: per-task 完美选 β 的 oracle 上限仅 +0.08, per-layer oracle 仅 +0.0008——**分区预算对配置误差不敏感, 不需要精调**。这构成部署简单性论据: 对照 DSA 的 1000 步 warm-up, TLI 一组固定配置覆盖 12/13 任务。

gate 的阈值。动态 gate 用 prefill 末段 far 统计识别 far mass 近零的层。阈值 τ 的真判决 (双任务梯度): $\tau=0.005$ 下 musique +0.23 / qasper -0.41; $\tau=0.015$ 下 +0.27 / -0.67——梯度单调, 真触发区间微损不崩 (对照静态版掉 4.8–5.9)。gate 因此定位为安全省算力的保守开关。

2.4 实现

TLI 在 sglang 生产形态下实现，选择链由四个 kernel 组件构成：

- **fused L1 块打分**：单个 Triton kernel 内完成 gather + 4bit 反量化（共享 scale 表）+ GEMV 打分 + 块级规约，32K 形态 3.6×；
- **L2 级联 dual kernel**：单 launch 完成 far/near 双池打分与分区 topk，池边界即因果边界（替代 eager 的 fine 矩阵因果 mask）；
- **统一稀疏 attention fused kernel**：gather + online softmax + bf16 直写，kernel 级 11–16×；
- **O(n) 精确增量索引**：每 token 增量更新块界与全量重建逐位一致，0.128ms 与序列长度无关。

系统侧三项工程对接生产：paged 寻址（选择输出逻辑位置经 req_to_token 间接寻址 KV pool，零拷贝）；per-layer 共享 index pool 预分配（decode 批量 select 的 launch 数与 batch size 无关）；CUDA graph 捕获区零 host 同步。设计约束来自 H20 形态：Tensor Core 吞吐仅 H100 的 15% 而 HBM 带宽同级——打分类 kernel 的第一性约束是带宽而非算力，TC 化与 TMA 转置布局实测均否决（算术强度指标显示纯 gather 路径已带宽饱和），kernel 主线是消除中间物化与合并 launch。

3 实验

3.1 评测指标

端到端质量。RULER 用官方 string_match_all ×100；LongBench 用各任务官方口径（F1 / Rouge / 准确率）平均。

注意力质量(mass 类指标)。对解码步 t 、层 ℓ ，设全维稠密注意力权重 $a_j = \text{softmax}(\langle q, k_j \rangle / \sqrt{d})_j$ 。定义两个口径：

- **选择覆盖**（selection coverage，记 C ）：以全维打分选出的 top- K 参考 token 集 M^* 为分母， $C(M) = \sum_{j \in M} a_j / \sum_{j \in M^*} a_j$ ，衡量量子空间打分替代全维打分后选中集合的信息保留。贡献 #1 的 0.729 即此口径（ $K=1024$ ）。
- **far 区召回**（far-region mass recall，记 R_{far} ）：分母限定 far 区（sink 与滑窗之外的 token）， $R_{\text{far}}(M) = \sum_{j \in M \cap F} a_j / \sum_{j \in F} a_j$ ，衡量稀疏选择对远端检索信号的捕获。三重判决的 0.811 与消融 A 的 0.804 均为此口径，数值差异来自实验批次不同（前者为旋转对判决实验的 8 样本均值，后者为降维实验的 8 样本均值，样本集不完全重合）；两处都以同一批次内的 tail32 基线做内部对照，跨批次不直接比较。

全部 mass 指标按 GQA kv-head 级分布加权平均（组内各 query head 的 a_j 分别计算后聚合），避免 head 平均掩盖 far mass 的头部集中。

3.2 端到端质量

本节在双基准上验证 TLI 的质量：RULER [16] (3 长度 $\times$ 11 任务 $\times$ n=100, NVIDIA 官方预生成) 考察长上下文检索, LongBench [17] 13 子集考察真实任务混合口径。对比方法中, TIA 是与本文同一管线下的第一代 training-free 块上界索引器 (块 min/max 上界 + 4bit 子空间量化, 无分区预算与感知 gate), 作为 TLI 最直接的结构消融对照; Quest 为下界近似的代表; KV 压缩三 baseline 走统一 monkeypatch 管线。全部实验用 Qwen3-8B [2] 真实权重; TLI 用终局配置 (sink/swa 强制保留不计入预算的严格口径)。

表 2: RULER 终表 (string_match_all $\times$ 100; TLI 为分区配置: (minmax, avg) 打分、 $\alpha=0.125$ 、 $\beta=0.25$ 、 $\gamma=0.125$ 、 $K_2=1024$; TLI-单池 = 同预算 $\alpha=0$ 单池消融臂)。

	FullKV	TIA@1024	TLI-单池	TLI@1024	Quest@1024
4K	91.59	91.63	91.63	91.49	87.91
8K	89.14	88.90	88.87	88.62	81.76
16K	85.41	84.53	82.77	83.68	70.18
总 AVG	88.71	88.35	87.76	87.93	79.95

如表所示, 三个观察成立。其一, TLI 对 Quest 的领先随长度超线性扩大 (+3.58 $\rightarrow$ +6.86 $\rightarrow$ +13.50): 16K 档 Quest 在多干扰检索任务上崩塌, TLI 同任务保持量级正确——根因是下界近似漏选随干扰项增多加剧, 上界粗筛无此劣化。其二, 分区相对单池消融臂的增益在 16K 才转正 (4K/8K 为 -0.14/-0.25, 16K 为 +0.91): 超长上下文是分区 far 检索的收益区, 16K 的分区增益集中于 multikey_3 (+5.0) 与 cwe (+5.4), 均为 vs 同配置单池臂的差分。其三, 绝对值解读须以同长度 FullKV 为基线——聚合列举类任务 FullKV 自身随长度退化 (multivalue 89.5 $\rightarrow$ 69.25 $\rightarrow$ 44.25 是模型列举能力上限), 稀疏方法在同长度上的差距才是稀疏效应。

LongBench 13 子集上 (表 3), TLI **50.54**——与 FullKV 50.36 持平 (+0.18, 噪声级边缘, Limitations 一节如实标注), vs Quest +2.82; 持平的诚实分解为 musique 单任务 +2.62 扛住其余 12 任务净 -0.30 (摊分后 +0.20 + -0.02 $\approx$ +0.18)。增益的结构清晰: 多跳 far-heavy 任务 musique 34.76 为全部方法最高 (vs FullKV +2.62、vs 同预算单池臂 +5.02), 是分区 far 检索的直接证据; 其余 12 任务互有胜负 (-1.78 至 +0.95; narrativeqa 为最大损失点 -1.78, hotpotqa +0.95 / 2wikimqa +0.94 / lcc +0.81 为正向)。KV 压缩三 baseline 的全量崩坏坐实 sink 论断: SnapKV 27.70 / H2O 更崩 (musique 0.63、hotpotqa 2.68)——无显式 sink 保送时 Qwen3-8B 首 token 即 EOS (§2.2 末段机理), 三者中仅代码类任务 (lcc 67.19 / 54.06) 部分幸存。预算配比的 任务形态依赖性以 $\beta \in \{0.25, 0.375\} \times \{\text{LongBench, RULER}\}$ 交叉表完整给出 (表 4): LongBench 多跳任务 $\beta=0.375$ 占优 (50.54 vs 50.41), RULER 合成 needle $\beta=0.25$ 占优 (87.93 vs 87.58)——对角占优但四格差距均 ≤ 0.35 , 与消融节的参数面平坦性一致; 两臂并报, 使用者按任务形态选择。逐任务族分解给出 β 让渡的边界判据: 真实任务全族成立 (最 far-heavy 的 musique 反而增益最大 +1.94), 合成 far-dense 族失效 (multikey_3 -2.00: far 候选数量爆炸使预算粒度主导)——

far-dense 检索是稀疏索引器全族难区 (Quest 同任务同构崩塌), 非 β 配比独有问题。

表 3: LongBench 13 子集终表 (各任务官方口径平均; TLI = 分区配置 (minmax, avg) $\alpha=0.125/\beta=0.375/\gamma=0.125$; TLI-单池 = 同预算 $\alpha=0$ 单池消融臂; KV 压缩三 baseline = 统一 monkeypatch 管线 + 1024 预算, 无 sink 保送适配)。

	FullKV	Quest	TIA	TLI-单池	TLI	SnapKV	H2O	PyramidKV
hotpotqa	53.48	45.74	53.89	54.93	54.43	23.64	2.68	25.10
2wikimqa	38.29	38.46	38.27	38.57	39.23	28.62	7.90	26.01
musique	32.14	27.25	32.28	29.74	34.76	8.61	0.63	8.99
passage_retrieval	100.00	98.50	99.50	99.50	99.50	4.00	2.50	4.50
qasper	44.17	40.13	44.03	44.31	44.51	16.84	10.18	18.58
multifieldqa	53.40	51.01	53.19	52.87	52.92	20.24	13.45	23.68
gov_report	33.17	32.13	33.43	33.49	33.29	19.21	17.23	20.56
qmsum	23.53	22.21	23.90	23.87	23.52	18.46	8.82	18.54
multi_news	24.93	24.95	24.73	24.64	24.62	21.04	22.79	21.37
narrativeqa	25.61	20.64	22.18	24.46	23.83	11.53	1.41	12.03
triviaqa	90.71	87.55	89.82	89.88	90.16	69.77	18.01	75.03
lcc	68.81	68.34	69.14	69.28	69.62	67.19	54.06	67.05
repobench	66.50	63.41	66.40	66.58	66.67	50.93	33.65	53.17
总分	50.36	47.72	50.06	50.16	50.54	27.70	14.87	28.82

表 4: β 两基准交叉表 (分区配置其余参数相同: $\alpha=0.125$ 、 $\gamma=0.125$ 、 $K_2=1024$; LongBench-13 与 RULER-33 全量)。

	$\beta=0.25$	$\beta=0.375$
LongBench-13	50.41	50.54
RULER-33	87.93	87.58

3.3 消融

子空间 (A)。低频 $d'=32$ 对全维 top-1024 的选择覆盖 $C=0.729$, 同管线 $d'=128$ 臂 0.732 (含量化与级联损失; 随机 0.32、高频 0.137 崩溃) ——位置稳定子空间存在。机理三重判决: tail32 = 16 个完整最低频旋转对 (频率单调 0.811/0.360/0.004、错位配对崩 0.567、16 对饱和); 选取方法学四象限 (表 1) 刻画可行域——逐维谱 0.759 与训练投影均败于配对纠缠, query 自适应 pair 选取 0.865 是 oracle 上界但不可索引化, per-layer 静态 pair 0.849 兼容索引但 e2e 反转 (重放 +3.8pt、e2e -0.50, musique -5.27, 与训练投影同构的口径鸿沟), tail32 是经 e2e 验证的零信号成本最优。降维三段判决: 无监督 PCA $d=16$ (跨 kv-head 共享 SVD 基) 近无损 (R_{far} 0.766 vs 同批次 tail32 0.804) 是唯一推荐 (per-head 基掉档至 0.752, 见图 2(c)); 训练投影 trace 成立 e2e 崩 (口径鸿沟);

非线性 (UMAP/t-SNE) 质量无增益且 fit 成本 80–167s/层-样本 vs 增量索引 0.128ms/token, 四个数量级不可行。跨 kv-head 共享 SVD 基 $d=16$ 在 8/8 样本追平 tail32 且优于 per-head 基——GQA head 冗余使 MLA 式单投影缓存的 training-free 代理可行。

分区。 far 区 token 级精筛接近 oracle (far-heavy 层 0.999); 聚类代表在严格 token 预算下无一致优势 (块 scatter-amax 0.09–0.39 最差) 且聚类中心非上界有漏选理论空洞——降级为负结果。分区 vs 单池 e2e 双基准成立 (LongBench +0.38 = 50.54–50.16, 表 3 可验算; RULER +0.17 = 87.93–87.76, =0.25 匹配臂), 与 trace 重放口径 (宽预算下单池微胜) 的分歧坐实: **分区收益的本质是紧预算下的预算分配, 而非候选质量。**

层跳过 (D’)。离线平均轮廓可跳 13/36 层 (precision 0.92–1.00) 但全局静态掩码跨任务不泛化 (多跳掉 4.8–5.9); prefill 动态信号 corr 0.924 防住反向错误, 真触发区间微损不崩——gate 是安全开关。

自适应 α/β 的否定。 per-request 在线分派 α/β 判 No-Go: oracle 上限 LongBench +0.08 / RULER +0.00, 且 +0.08 全部可由噪声正向选择偏差解释 (非 musique 12 任务 $|\Delta|$ 中位 0.17)。信号零成本可得, 但参数面平坦使自适应无杠杆。同一信号的最佳用途是 gate (安全价值) 而非 β 分派 (无精度价值)。粒度细化到层同样无杠杆 (per-layer oracle 增益均值 +0.0008) ——任务与层两粒度双重否定, 转译为部署简单性论据。

离线重放与端到端的口径鸿沟。 我们对五种近/远端打分组合做了离线 trace 重放与端到端评测的双重排名: 重放质量排名第 4 的组合 (近端取均值聚合的配置) 在端到端评测中取得全场最高分 50.54——两种口径的排名系统性反转。该鸿沟在子空间选取维度上再次出现: per-layer 静态 pair 臂重放口径 +3.8pt (R_{far} 0.849 vs 0.811), 同配置 e2e 却 -0.50 (50.04 vs 50.54, musique -5.27) ——prefill 统计派生的选择基 (训练投影与静态 pair 同构) 在 decode 查询漂移下失效。这说明离线代理指标不能替代端到端评测, kernel microbench 与 e2e 必须都测都报告。

3.4 Kernel 级 Microbench

选择链相对 dense 全维打分的加速比: 32K 1.46 $\times$ 、64K 2.77 $\times$ 、128K 5.09 $\times$ (合成数据已标注, trace 重放口径)。同机三方对比 (官方 kernel 原样接入统一 harness, 131K cudaEvent): Quest 0.107ms / DSA 0.503ms / TLI 0.787ms。延迟排名 Quest < DSA < TLI, 如实报告——TLI 当前的优势在算法结构侧: 每 token 索引 MAC ≈ 258 (DSA 的 1/32)、索引存储总量 3 $\times$ 低于 Quest (336B/token vs 约 1KB/token, 全 head 汇总; Quest 逐 32 个 head 建索引而 TLI 仅建 8 个 kv-head)、质量 vs Quest LongBench +2.82 / RULER +7.98。131K 下三家都远离 HBM bound, 排名反映实现成熟度而非算法上界。

3.5 端到端速度

e2e 终值 (Qwen3-30B-A3B, H20 $\times$ 2): 64K 单请求 1.285 $\times$ (16.39s vs dense 21.06s) ——稀疏理论流量收益首次在 e2e 净兑现; 32K 档 0.77 $\times$ (短上下文固定开销未能覆盖); TP2 bs16 64K 档 0.92 $\times$, 差 8% 如实归因为 launch-bound (逐请求 Python 循环使 GPU 名义满载而带宽 util 仅

10–11%), 跨请求批量化已验证 $3.8\times$ 为修复方向。8B 稳态 ($\text{bs}16 \times S=30K \times n=256$; 基线 733.9s 与 65.0ms 均为 TLI 自身 kernel 化前, 非 dense): decode step 65.0 $\rightarrow$ 33.5ms (自身 $1.94\times$, 优化后为 dense 40.4ms 的 $1.21\times$); prefill 733.9 $\rightarrow$ 183.4s (自身 $4.00\times$, 对 dense 仍慢 $1.60\times$ ——8B 的 8 个 kv-head 使每层 gather 形态更重, 30B 的 4 头形态同一实验 prefill 耗时为 dense 的 0.77 倍 ($1.30\times$ 加速), kv-head 数是 prefill 差异的主变量)。

3.6 Profiling 方法论发现

逐 kernel microbench 与生产 e2e 存在系统性口径差: select 热路径的 3 处 host 同步 (`.item()` 与 `.any()`) 在生产形态造成约 10 万次队列排空, 合成 bench 无 GPU 队列时完全测不出, 消除后同型负载 prefill 降低 6.7%。同步消除类优化必须在 e2e 层验证。我们将此与离线重放排名不可替代 e2e 判决的观察合并为一条方法论: kernel 级与 e2e 两层评测都测、都诚实报告。

4 相关工作

稀疏注意力索引。Quest 用 page 采样构造下界近似, KV 压缩类 (SnapKV/H2O/PyramidKV) 在 prefill 时一次性丢弃 KV。TLI 与它们的差异在三点: 分数表示取上界 (vs 下界——上界家族在 RULER 总 AVG 上领先 Quest +8.40, 是长上下文质量分化的主要根源)、预算组织取分区 (vs 全池)、两级级联 (vs 单级)。我们在统一口径适配 SnapKV/H2O/PyramidKV 时发现: 无显式 sink 保送的实现在 Qwen3-8B 上首 token 即 EOS——sink 在浅层不获选择信号但承载深层 0.59 的 attention mass, 逐层恶性畸变。这既是对这类 baseline 适配的公平性修正, 也旁证 sink 保送的必要性。

训练类索引。DSA [13] (DeepSeek V3.2) 用 $I = \sum w \cdot \text{ReLU}(q \cdot k)$ 训练选择器, 64 头 $\times$ 128 维 FP8 top-2048, warm-up 1000 步; MoBA [14] 用门控块稀疏。TLI training-free/weight-free, 与其在 kernel 级统一 harness 对比。两者构成方法论分界: DSA 用训练换选择能力, 可学任意投影; training-free 只能依赖与查询分布无关的位置先验——trace 离线成立而 e2e 崩坏的口口径鸿沟正是这条分界线的实证刻画。

两级结构。HISA (COLM 2026) 验证 block-coarse + token-refine 形态有效——「two-level」本身不是本文创新。TLI 的增量是两个正交维度的系统刻画: 表示 (上界 vs 下界) 与预算组织 (分区 vs 全池) 的质量-速度影响。

推理系统。FlashAttention 系优化计算核, PagedAttention/vLLM 优化显存组织。TLI 与它们正交, 在 sglang 生产形态集成。

5 局限与未来工作

精度侧: LongBench 对 FullKV 的领先幅度在噪声边缘 (+0.18); RULER 最优臂 87.93 仍低于 FullKV 88.71 (−0.78), 残余代价集中于 multikey_3 (16K: 75–80 vs TIA 89)——4bit 预算粒度在超多干扰 key 任务上主导。速度侧: 多请求批量形态仍差 dense 8% (launch-bound), 跨

请求批量化 forward_extend 为明确修复方向；三方 indexer 延迟排名当前第三，跨请求批量化的 kernel 化为兑现路径。规模与模型族侧：全部结论在 Qwen3 单模型族上取得——同族 32B 上子空间机制强度递减（entry recall 口径 0.66–0.87 vs 全维差距 ≤ 0.08 ，机制存在、如实报告），但跨模型族外推未验证：旋转对机理依赖 rotate_half（GPT-NeoX 式）布局下「尾维 = 低频完整对」的对应；interleaved（GPT-J 式）布局下同一映射不成立，须重推维度选择；无 RoPE 或部分旋转模型上「位置稳定低频子空间」这一前提本身待检验。MLA 架构的 latent 索引（DeepSeek 系）是 future work。上界无漏选的性质只在「子空间打分口径」内成立，跨口径漏选已有静态 pair 臂类实证（重放增益不可外推）。gate 的 far 统计为 per-layer 单值，混合 batch 下跨请求污染（生产语义应 per-row）。

附录 A：实验编号总索引

全部实验编号与系统里程碑的脚本到结论映射（含 commit 号、对拍口径、负结果入册）见随源码发布的配套实验日志。

附录 B：可复现性

H20-3e $\times 2$ (141GB) , torch 2.8.0+cu128, sglang two-level-indexer 分支；RULER 官方预生成（KVCache-Factory 镜像）/ LongBench v1 全量 / Qwen3-8B、30B-A3B、32B 真实权重；string_match_all 官方口径打分；e2e 差分法采用稀疏/稠密配置交替运行的对照方式。

参考文献

- [1] DeepSeek-AI. DeepSeek-R1: Incentivizing Reasoning Capability in LLMs via Reinforcement Learning. arXiv:2501.14348, 2025.
- [2] Qwen Team. Qwen3 Technical Report. arXiv:2505.09388, 2025.
- [3] T. Dao, D. Y. Fu, S. Ermon, A. Rudra, and C. Ré. FlashAttention: Fast and Memory-Efficient Exact Attention with IO-Awareness. In *NeurIPS*, 2022.
- [4] W. Kwon, Z. Li, S. Zhuang, Y. Sheng, L. Zheng, C. H. Yu, J. E. Gonzalez, H. Zhang, and I. Stoica. Efficient Memory Management for Large Language Model Serving with PagedAttention. In *SOSP*, 2023.
- [5] Y. Tang, L. Lin, Y. Cao, S. Li, F. Yang, Y. Wang, and T. Wu. Quest: Query-Aware Sparsity for Efficient Long-Context LLM Inference. In *ICLR*, 2025.
- [6] Y. Li, Y. Huang, B. Yang, Y. Li, Y. Liu, and M. Qiu. SnapKV: LLM Knows What You Are Looking For Before Generation. In *NeurIPS*, 2024.

- [7] Z. Zhang, Y. Sheng, T. Zhou, D. Chen, L. Zheng, B. Chen, L. Cai, M. Yan, Y. Yu, J. Tang, J. Xu, P. Zhang, and R. Chen. H2O: Heavy-Hitter Oracle for Efficient Generative Inference of Large Language Models. In *NeurIPS*, 2023.
- [8] Z. Cai, Y. Zhang, B. Wang, X. Liu, H. Zhao, Y. Lu, Y. Wang, X. Sun, K. Liu, and Z. Duan. PyramidKV: Dynamic KV Cache Compression Based on Pyramidal Information Funneling. arXiv:2406.02069, 2024.
- [9] G. Xiao, Y. Tian, B. Chen, S. Han, and M. Lewis. Efficient Streaming Language Models with Attention Sinks. In *ICLR*, 2024.
- [10] I. Beltagy, M. E. Peters, and A. Cohan. Longformer: The Long-Document Transformer. arXiv:1904.07785, 2020.
- [11] M. Zaheer, M. Guruganesh, K. A. Dubey, J. Ainslie, C. Alberti, S. Ontañón, P. Pham, A. Ravula, Q. Wang, L. Yang, and A. Ahmed. Big Bird: Transformers for Longer Sequences. In *NeurIPS*, 2020.
- [12] SparQ Attention: Accelerating LLM Inference with Accurate KV Retrieval, Minimized Decoding Costs, and No Fine-Tuning. arXiv:2406.09050, 2024.
- [13] DeepSeek-AI. DeepSeek-V3.2-Exp Technical Report: Boosting Long-Context Efficiency with Exact Sparse Attention. 2025.
- [14] Moonshot AI. MoBA: Mixture of Block Attention for Efficient Long-Context LLMs. arXiv:2502.13189, 2025.
- [15] HISA: Efficient Hierarchical Indexing for Fine-Grained Sparse Attention. In *COLM*, 2026. arXiv:2603.28458.
- [16] C.-P. Hsieh, S. Sun, S. Krizan, S. Ganti, J. Zhang, B. Kulis, K. Papayiannis, M. Fofanos, N. Rudrajit, and C. Tigges. RULER: What’s the Real Context Size of Your Long-Context Language Models? arXiv:2404.06654, 2024.
- [17] Y. Bai, X. Lv, J. Zhang, H. Zhao, X. Qi, L. Huang, Z. Du, X. Wang, Y. Zheng, Y. Zheng, J. Zhang, Y. Li, T. Su, and J. Tang. LongBench: A Bilingual, Multitask Benchmark for Long Context Understanding. In *ACL*, 2024.